

Лабораторна робота № 1

Вхідний аналіз набору даних

Дисципліна: Інтелектуальний аналіз та візуалізація даних (СК26) **Тривалість:** 2 год аудиторно + 3 год самостійної роботи · **Максимальна оцінка:** 4 бали

Мета роботи

Пригадати роботу в Jupyter Notebook, бібліотеці pandas та побудову графіків — і зробити це не на навчальному прикладі, а на реальному файлі, який ніхто не готував спеціально для вас.

Ця робота виконується **до першої лекції**. Нічого нового знати не потрібно: усе, що знадобиться, ви вже проходили в попередніх курсах. Усі поняття, яких ви тут торкнетесь мимохідь, отримають назви й пояснення на лекціях 3 і 4.

Дані

Файл 20171129_FINAL_FINAL.xlsx , аркуш Sheet1 — спостереження космічної погоди за 28 серпня — 22 вересня 2017 року, зібрані з трьох різних джерел.

Файл видається як є, рівно в тому вигляді, у якому його колись вивантажили. Ніхто не приводив його до ладу, і саме в цьому сенс: справжні дані здебільшого надходять саме такими.

Що ви маєте зробити

Етап	Зміст	Де
1	Розібратися, що взагалі лежить у файлі	аудиторно
2	Виділити три таблиці й привести їх до робочого вигляду	аудиторно
3	Скласти паспорт даних: що є, чого бракує, що виглядає дивно	аудиторно
4	Об'єднати три таблиці в одну	аудиторно
5	Побудувати п'ять графіків, кожен — відповідь на питання	аудиторно + самостійно
6	Порівняти два графіки одних і тих самих даних	самостійно
7	Записати три спостереження про дані	самостійно
8	Декларація про використання інструментів ШІ	самостійно

Що здається

- Цей файл .ipynb із заповненими розв'язками. **Ноутбук має виконуватися згори донизу на чистому ядрі** (Kernel → Restart & Run All) без помилок — це перевіряється першою дією на захисті.
- Файл master_hourly.csv — об'єднана таблиця з етапу 4.
- Експорт ноутбука у HTML або PDF.
- Заповнена декларація (етап 8). Без неї фінальна самоперевірка не проходить.

Критерії оцінювання

Бали	Що досягнуто
0	Дані не опрацьовано, графіки не побудовано або побудовано з грубими помилками
1	Таблиці прочитано й кілька графіків побудовано, але типи графіків не відповідають даним, дивних значень не помічено
2	Таблиці розібрано й об'єднано, графіки коректні та підписані, але висновків під ними немає або вони формальні
4	Усе вище виконано, знайдено й пояснено дивні значення, під кожним графіком є змістовний висновок про дані

Головне про оцінку: бали ставляться не за наявність графіка, а за речення під ним. Код, який нічого не пояснює, коштує двох балів з чотирьох.

Нагадування про Jupyter

Якщо давно не працювали — три речі, які знадобляться сьогодні:

- Shift+Enter виконує клітинку, Esc A / Esc B додає клітинку вище / нижче, Esc M перетворює клітинку на текстову (Markdown), Esc Y — назад на код.
- **Порядок виконання має значення.** Якщо ви правили клітинки в довільному порядку, результат може залежати від історії запусків. Перед здачею обов'язково **Kernel → Restart & Run All** — так ви побачите ноутбук очима викладача.
- Текстові клітинки — не прикраса. Висновки пишуться в них, а не в коментарях до коду.

Крок 0. Ваші дані та варіант

Заповніть три змінні й виконайте обидві клітинки. Друга надрукує**ваше індивідуальне завдання** — воно відрізняється від завдання сусіда.

```
In [1]:
ПІБ = 'Басараб Дмитрій'      # напр. 'Шевченко Тарас'
ГРУПА = 'ШІ-32'              # напр. 'КН-31'
ВАРІАНТ = 1                  # ваш номер за списком групи
```

assert ПІБ **and** ГРУПА **and** ВАРІАНТ, 'Заповніть ПІБ, ГРУПУ та ВАРІАНТ'

```
In [2]:
# --- клітинку не редагувати: вона видає ваше персональне завдання -----
ПОТОКИ = ['P>1', 'P>5', 'P>10', 'P>30', 'P>50', 'P>100', 'E>0.8', 'E>2.0']
```

```
ПАРИ = [('швидкість вітру', 'густина вітру'),
         ('швидкість вітру', 'потік P>10'),
         ('густина вітру', 'потік P>1'),
         ('радіопотік F10.7', 'потік P>10'),
         ('радіопотік F10.7', 'швидкість вітру'),
         ('потік E>0.8', 'потік P>10')]
```

АГРЕГАТИ = ['середнє', 'максимум', 'медіана', 'мінімум']

```
ПИТАННЯ = [
    'Скільки годин за все вікно ваш потік перевищував своє власне медіанне значення?',
    'У яку добу середнє значення вашого потоку було найбільшим? А найменшим?',
    'О котрій годині доби потік E>0.8 у середньому найбільший? Побудуйте графік середнього за годинами доби.',
    'Яка частка рядків об'єднаної таблиці має пропуск хоча б в одному стовпці?',
    'У який день радіопотік F10.7 був найбільшим і чи збігається цей день з піком вашого потоку?',
    'Порівняйте медіану вашого потоку за перший і за другий тиждень спостережень. У скільки разів вони відрізняються?',
    'Скільки годин поспіль тривала найдовша неперервна серія «активних» годин (група з етапу 4)?',
    'Який зі стовпців об'єднаної таблиці має найбільший розкид відносно власного середнього?',
    'Яку частку сумарного значення вашого потоку за все вікно дали 24 години навколо піку?',
    'Скільки різних діб потрапило у групу «активні» і скільки — у групу «дуже активні»?',
]
```

```
i = int(ВАРІАНТ)
завдання = {
    'ваш потік':          ПОТОКИ[(i * 3 + 1) % 8],
    'ваша пара для графіка 3': ' та '.join(ПАРИ[(i * 5 + 2) % 6]),
    'ваш агрегат для етапу 4': АГРЕГАТИ[(i * 5 + 1) % 4],
    'ваше додаткове питання': ПИТАННЯ[(i * 11 + 5) % 10],
}
```

```
print('ІНДИВІДУАЛЬНЕ ЗАВДАННЯ · %s, %s, варіант %d' % (ПІБ, ГРУПА, i))
print('=' * 78)
for k, v in завдання.items():
    print('%-28s %s' % (k + ': ', v))
```

ІНДИВІДУАЛЬНЕ ЗАВДАННЯ · Басараб Дмитрій, ШІ-32, варіант 1

```
=====
ваш потік:          P>50
ваша пара для графіка 3:  швидкість вітру та потік P>10
ваш агрегат для етапу 4:  медіана
ваше додаткове питання:  Скільки годин поспіль тривала найдовша неперервна серія «активних» годин (група з етапу 4)?
Далі за текстом «ваш потік» означає стовпець, названий у першому рядку завдання.
```

In [3]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

pd.set_option('display.width', 200)
pd.set_option('display.max_columns', 40)
plt.rcParams.update({'figure.dpi': 110, 'axes.spines.top': False,
                    'axes.spines.right': False, 'font.size': 9})

ФАЙЛ = '20171129_FINAL_FINAL.xlsx'
```

Етап 1. Що взагалі лежить у файлі

Перше правило роботи з незнайомими даними: спершу подивитися, потім рахувати.

Завдання 1.1

Спробуйте прочитати аркуш Sheet1 звичайним способом — `pd.read_excel(ФАЙЛ)` — і виведіть перші рядки та типи стовпців.

Очікуваний результат: результат буде дивним. Подивіться на назви стовпців і на те, які там типи даних. Поясніть у наступній клітинці, чому так вийшло.

```
In [4]:
# ВАШ КОД
data = pd.read_excel(ФАЙЛ)
df = pd.DataFrame(data)

df
Out[4]:
```

	Unnamed: 0	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	Unnamed: 2	Unnamed: 3	Unnamed: 4	Unnamed: 5	Unnamed: 6	Unr
0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN	NaN	NaN	
2	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN	NaN	NaN	
3	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN	NaN	NaN	
4	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN	NaN	NaN	
...	...	...	...	...	...	...	...	
7220	NaN	2017	9	21	2335	58017	84900	
7221	NaN	2017	9	21	2340	58017	85200	
7222	NaN	2017	9	21	2345	58017	85500	
7223	NaN	2017	9	21	2350	58017	85800	
7224	NaN	2017	9	21	2355	58017	86100	

7225 rows x 32 columns

Відповідь 1.1: тому що таблиця містить перші рядки як метадані, через це збилися типи даних стовбців і рядків, збилися і назви

Завдання 1.2

Прочитайте аркуш ще раз, але **без заголовка**: `pd.read_excel(ФАЙЛ, header=None)` . Виведіть його розмір і подивіться на перші 30 рядків.

```
In [5]:
RAW = pd.DataFrame(pd.read_excel(ФАЙЛ, header=None))
RAW.shape
RAW.head(30)
```

Out[5]:

	0	1	2	3	4	5	6	7	8	9	10	11
0	NaN	ftp://ftp.swpc.noaa.gov/pub/lists/particle/	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	NaN	:Data_list: 20170901_Gs_part_5m.txt	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	NaN	:Created: 2017 Sep 02 0011 UTC	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	NaN	# Prepared by the U.S. Dept. of Commerce, NOAA...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
5	NaN	# Please send comments and suggestions to SWPC...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
6	NaN	#	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
7	NaN	# Label: P > 1 = Particles at >1 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
8	NaN	# Label: P > 5 = Particles at >5 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
9	NaN	# Label: P >10 = Particles at >10 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
10	NaN	# Label: P >30 = Particles at >30 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
11	NaN	# Label: P >50 = Particles at >50 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
12	NaN	# Label: P>100 = Particles at >100 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
13	NaN	# Label: E>0.8 = Electrons at >0.8 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
14	NaN	# Label: E>2.0 = Electrons at >2.0 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
15	NaN	# Label: E>4.0 = Electrons at >4.0 Mev	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
16	NaN	# Units: Particles = Protons/cm2-s-sr	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
17	NaN	# Units: Electrons = Electrons/cm2-s-sr	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
18	NaN	# Source: GOES-15	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
19	NaN	# Location: W135	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
20	NaN	# Missing data: -1.00e+05	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
21	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
22	NaN	5-minute GOES-15 Solar Particle and Electron ...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
23	NaN	NaN	NaN	NaN	NaN	Modified	Seconds	NaN	NaN	NaN	NaN	NaN
24	NaN	# UT	C D	ate	Time	Julian	of the	NaN	NaN	NaN	NaN	NaN
25	NaN	# YR	MO	DA	HHMM	Day	Day	P > 1	P > 5	P >10	P >30	P >50
26	NaN	2017	8	28	0	57993	0	12	0.26	0.18	0.114	0.104
27	NaN	2017	8	28	5	57993	300	19.4	0.69	0.314	0.112	0.0612
28	NaN	2017	8	28	10	57993	600	8.48	0.168	0.13	0.0717	0.0614
29	NaN	2017	8	28	15	57993	900	15.4	0.566	0.198	0.0926	0.0566

Завдання 1.3

Для кожного стовпця порахуйте, скільки в ньому заповнених клітинок (`RAW.notna().sum()`), і виведіть результат.

Очікуваний результат: 32 числа. Серед них будуть нулі та згустки великих значень. За цими згустками видно, що в аркуші не одна таблиця, а кілька, вставлені поруч.

Питання: скільки таблиць в аркуші і які стовпці займає кожна?

```
In [6]:
# ВАШ КОД
RAW.notna().sum()
```

```
Out[6]:
0      0
1    7223
2    7202
3    7202
4    7202
5    7203
6    7203
7    7198
8    7198
9    7198
10   7198
11   7198
12   7198
13   7198
14   7198
15      0
16     32
17     26
18     26
19     26
20      0
21      0
22      0
23      0
24    601
25    601
26    608
27    602
28    602
29    602
30    602
31    602
dtype: int64
```

Відповідь 1.3: 3 таблиці, перша займає 2-14 стовбці, 2 займає 16-19 стовбці, 3 займає 24-31 стовбці.

Завдання 1.4

Над кожною таблицею є кілька текстових рядків — це службовий опис від тих, хто дані збирав. Виведіть їх і випишіть для кожної таблиці джерело даних та одиниці вимірювання.

Це найкорисніші рядки з хвилини роботи: жодної з цих відомостей у самій таблиці немає, і без них ви не знаєте те, у чому вимірюєте.

```
In [7]:
print("A",RAW.iloc[18,1],RAW.iloc[16,1],RAW.iloc[17,1])
print("B",RAW.iloc[18,16],RAW.iloc[26,19])
print("C",RAW.iloc[2,26],RAW.iloc[4,26],RAW.iloc[5,26])

A | # Source: GOES-15 | # Units: Particles = Protons/cm2-s-sr   # Units: Electrons = Electrons/cm2-s-sr
B | # Prepared by the U.S. Dept. of Commerce, NOAA, Space Weather Prediction Center | Radio Flux 10.7
C | SOHO CELIAS Proton Monitor | Proton speed [km/sec]   Proton density [protons per cubic centimeter]
```

Відповідь 1.4:

Таблица	Джерело	Одиниці вимірювання
A	GOES-15	Protons/cm2-s-sr,Electrons/cm2-s-sr
B	U.S. Dept. of Commerce, NOAA, Space Weather Prediction Center	Radio Flux 10.7
C	SOHO CELIAS Proton Monitor	km/sec,protons per cubic centimeter

Етап 2. Три таблиці в робочому вигляді

У файлі три таблиці. Ось що в них лежить — решту ви вже знайшли самі:

Таблиця	Стовпці аркуша	Що це	Один рядок =
A	B–O	вимірювання із супутника GOES-15: потоки частинок різної енергії	5 хвилин
B	Q–T	добовий показник сонячної активності F10.7	доба
C	Y–AF	швидкість і густина сонячного вітру	година

Завдання 2.1

```
Виділіть кожну таблицю в окремий DataFrame — назвіть їх A , B і C . Дайте стовпцям осмислені назви й перетворіть значення на числа ( pd.to_numeric(..., errors='coerce') стане в пригоді).

In [8]:
A = RAW.iloc[26:7226, 1:15].copy().reset_index(drop=True)
A.columns = ['YYYY', 'MM', 'DD', 'hhmm', 'Modified_Julian_Day', 'Seconds_of_the_day', 'P>1', 'P>5', 'P>10', 'P>30', 'P>50', 'P>100', 'E>0.8', '']

B = RAW.iloc[27:52, 16:20].copy().reset_index(drop=True)
B.columns = ['YYYY', 'MM', 'DD', 'F10.7']

C = RAW.iloc[27:628, 26:32].copy().reset_index(drop=True)
C.columns = ['YYYY', 'MM', 'DD', 'hh', 'speed', 'density']

for df in [A, B, C]:
    for col in df.columns:
        df[col] = pd.to_numeric(df[col], errors='coerce')

print(A)
print(B)
print(C)
```

	YYYY	MM	DD	hhmm	Modified_Julian_Day	Seconds_of_the_day	P>1	P>5	P>10	P>30	P>50	P>100	E>0.8	E>2.0
0	2017	8	28	0	57993	0	12.00	0.260	0.180	0.1140	0.1040	0.0793	23600.0	1180.0
1	2017	8	28	5	57993	300	19.40	0.690	0.314	0.1120	0.0612	0.0251	23100.0	1160.0
2	2017	8	28	10	57993	600	8.48	0.168	0.130	0.0717	0.0614	0.0304	22200.0	1090.0
3	2017	8	28	15	57993	900	15.40	0.566	0.198	0.0926	0.0568	0.0251	20400.0	997.0
4	2017	8	28	20	57993	1200	6.41	0.156	0.118	0.0597	0.0494	0.0251	18500.0	875.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
7195	2017	9	21	2335	58017	84900	21.90	0.361	0.202	0.0840	0.0717	0.0475	143000.0	32900.0
7196	2017	9	21	2340	58017	85200	14.10	0.343	0.309	0.1180	0.0679	0.0328	143000.0	32100.0
7197	2017	9	21	2345	58017	85500	27.10	0.465	0.237	0.1060	0.0593	0.0251	140000.0	32500.0
7198	2017	9	21	2350	58017	85800	23.70	0.360	0.205	0.1270	0.0910	0.0363	140000.0	32700.0
7199	2017	9	21	2355	58017	86100	32.40	0.377	0.166	0.1060	0.0593	0.0251	143000.0	33900.0

[7200 rows x 14 columns]

YYYY MM DD F10.7

0	2017	8	28	82
1	2017	8	29	84
2	2017	8	30	87
3	2017	8	31	92
4	2017	9	1	93
5	2017	9	2	100
6	2017	9	3	120
7	2017	9	4	140
8	2017	9	5	121
9	2017	9	6	133
10	2017	9	7	129
11	2017	9	8	117
12	2017	9	9	107
13	2017	9	10	100
14	2017	9	11	80
15	2017	9	12	76
16	2017	9	13	75
17	2017	9	14	74
18	2017	9	15	73
19	2017	9	16	72
20	2017	9	17	72
21	2017	9	18	72
22	2017	9	19	71
23	2017	9	20	74
24	2017	9	21	73

YYYY MM DD hh speed density

0	17	8	28	0	285	3.0
1	17	8	28	1	305	3.4
2	17	8	28	2	309	1.7
3	17	8	28	3	304	2.0
4	17	8	28	4	302	2.3

...	...	...	...	...	...	...
596	17	9	21	20	379	1.8
597	17	9	21	21	380	1.8
598	17	9	21	22	387	1.1
599	17	9	21	23	380	1.0
600	17	9	22	0	381	1.0

[601 rows x 6 columns]

Завдання 2.2

У кожній таблиці дата й час записані**по-різному** й розкидані по кількох стовпцях. Зберіть для кожної таблиці один стовпець ts типу datetime .

Після цього обов'язково виведіть для кожної таблиці найранішу й найпізнішу дату.

Очікуваний результат: усі три таблиці мають лежати в межах серпня–вересня 2017 року. Якщо у вас вийшов інший рік — придивіться, як записано рік у тій таблиці, і виправте.

In [9]:

```
hoursA = A['hhmm'] //100
minsA = A['hhmm'] % 100
A['ts'] = pd.to_datetime({
    'year': A['YYYY'],
    'month': A['MM'],
    'day': A['DD'],
    'hour': hoursA,
    'minute':minsA
})

B['ts'] = pd.to_datetime({
    'year': B['YYYY'],
    'month': B['MM'],
    'day': B['DD'],
})

C['ts'] = pd.to_datetime({
    'year': C['YYYY'] +2000,
    'month': C['MM'],
    'day': C['DD'],
    'hour': C['hh']
})
A
```

Out[9]:

	YYYY	MM	DD	hhmm	Modified_Julian_Day	Seconds_of_the_day	P>1	P>5	P>10	P>30	P>50	P>100
0	2017	8	28	0	57993	0	12.00	0.260	0.180	0.1140	0.1040	0.0793
1	2017	8	28	5	57993	300	19.40	0.690	0.314	0.1120	0.0612	0.0251
2	2017	8	28	10	57993	600	8.48	0.168	0.130	0.0717	0.0614	0.0304
3	2017	8	28	15	57993	900	15.40	0.566	0.198	0.0926	0.0568	0.0251
4	2017	8	28	20	57993	1200	6.41	0.156	0.118	0.0597	0.0494	0.0251
...	...	...	...	...	...	...	...	...	...	...	...	...
7195	2017	9	21	2335	58017	84900	21.90	0.361	0.202	0.0840	0.0717	0.0475
7196	2017	9	21	2340	58017	85200	14.10	0.343	0.309	0.1180	0.0679	0.0328
7197	2017	9	21	2345	58017	85500	27.10	0.465	0.237	0.1060	0.0593	0.0251
7198	2017	9	21	2350	58017	85800	23.70	0.360	0.205	0.1270	0.0910	0.0363
7199	2017	9	21	2355	58017	86100	32.40	0.377	0.166	0.1060	0.0593	0.0251

7200 rows x 15 columns

Самоперевірка етапу 2. Клітинка має виконатися без помилок.

In [10]:

```
assert len(A) == 7200, 'у таблиці A має бути 7200 рядків, а є %d' % len(A)
assert len(B) == 25, 'у таблиці B має бути 25 рядків, а є %d' % len(B)
assert len(C) == 601, 'у таблиці C має бути 601 рядок, а є %d' % len(C)
for назва, t in [('A', A), ('B', B), ('C', C)]:
    рік = pd.to_datetime(t['ts']).dt.year
    assert рік.min() == 2017 and рік.max() == 2017, 'у таблиці %s рік не 2017 — перевірте збирання дати' % назва
print('Етап 2 пройдено')
```

Етап 2 пройдено

Етап 3. Паспорт даних

Завдання 3.1

Для кожної таблиці виведіть: розмір, типи стовпців, кількість пропусків у кожному стовпці, кількість повних дублікатів рядків і описові статистики (`describe()`).

```
In [11]:
# ВАШ КОД
print(A.describe())
print(B.describe())
print(C.describe())
```

	YYYY	MM	DD	hhmm	Modified_Julian_Day	Seconds_of_the_day	P>1	P>5	P>10	P>30	P>50	P>100	E
>0.8 \													
count	7200.0	7200.000000	7200.000000	7200.000000	7200.000000	7200.000000	7197.000000	7197.000000	7197.000000	7197.000000	7197.000000	7197.000000	
7197.000000	7197.000000												
mean	2017.0	8.840000	13.960000	1177.500000	58005.000000	43050.000000	689.325064	156.626057	76.474020	18.838604	7.446840	1.	
65929	81862.741801												
min	2017.0	8.000000	1.000000	0.000000	57993.000000	0.000000	0.429000	0.151000	0.117000	0.057600	0.045500	0.02240	
4.300000													
25%	2017.0	9.000000	7.000000	588.750000	57999.000000	21525.000000	11.700000	0.279000	0.186000	0.098400	0.059700	0.026	
30	22200.000000												
50%	2017.0	9.000000	13.000000	1177.500000	58005.000000	43050.000000	55.400000	0.632000	0.376000	0.146000	0.086600	0.03	
630	68600.000000												
75%	2017.0	9.000000	19.000000	1766.250000	58011.000000	64575.000000	560.000000	107.000000	35.800000	0.990000	0.249000	0.	
06700	143000.000000												
max	2017.0	9.000000	31.000000	2355.000000	58017.000000	86100.000000	32500.000000	2890.000000	1330.000000	399.000000	191.000000		
61.500000	259000.000000												
std	0.0	0.366632	8.775483	692.481902	7.211603	24943.113498	1625.968447	390.921861	222.362627	67.265595	28.620524	7.1588	
9	65728.005824												

```
count 7197.000000      7200
mean  11401.502123  2017-09-09 11:57:30
min    0.133000  2017-08-28 00:00:00
25%    552.000000  2017-09-03 05:58:45
50%    4290.000000  2017-09-09 11:57:30
75%    14100.000000  2017-09-15 17:56:15
max    110000.000000  2017-09-21 23:55:00
std    16920.617446      NaN
      E>2.0      ts
count 7197.000000      7200
mean  11401.502123  2017-09-09 11:57:30
min    0.133000  2017-08-28 00:00:00
25%    552.000000  2017-09-03 05:58:45
50%    4290.000000  2017-09-09 11:57:30
75%    14100.000000  2017-09-15 17:56:15
max    110000.000000  2017-09-21 23:55:00
std    16920.617446      NaN
      YYYY      MM      DD      F10.7      ts
count 25.0 25.000000 25.000000 25.000000      25
mean  2017.0 8.840000 13.960000 92.680000 2017-09-09 00:00:00
min  2017.0 8.000000 1.000000 71.000000 2017-08-28 00:00:00
25%  2017.0 9.000000 7.000000 74.000000 2017-09-03 00:00:00
50%  2017.0 9.000000 13.000000 84.000000 2017-09-09 00:00:00
75%  2017.0 9.000000 19.000000 107.000000 2017-09-15 00:00:00
max  2017.0 9.000000 31.000000 140.000000 2017-09-21 00:00:00
std  0.0 0.374166 8.955817 22.206831      NaN
      YYYY      MM      DD      hh      speed      density      ts
count 601.0 601.000000 601.000000 601.000000 601.000000 601.000000 601.000000      601
mean  17.0 8.840266 13.973378 11.480865 506.547421 2.907654 2017-09-09 12:00:00
min  17.0 8.000000 1.000000 0.000000 -1.000000 -1.000000 2017-08-28 00:00:00
25%  17.0 9.000000 7.000000 5.000000 447.000000 1.800000 2017-09-03 06:00:00
50%  17.0 9.000000 13.000000 11.000000 517.000000 2.400000 2017-09-09 12:00:00
75%  17.0 9.000000 19.000000 17.000000 584.000000 3.400000 2017-09-15 18:00:00
max  17.0 9.000000 31.000000 23.000000 806.000000 31.700000 2017-09-22 00:00:00
std  0.0 0.366664 8.781000 6.938063 125.073291 2.637873      NaN
```

Завдання 3.2 — дивні значення

Подивіться на рядок `min` у таблиці `describe()` для таблиці `C`.

Швидкість і густина — фізичні величини, які **не можуть бути від'ємними**. Знайдіть від'ємні значення, порахуйте, скільки їх, і поверніться до службового опису з завдання 1.4: там написано, що вони означають.

Замініть ці значення на `NaN` і покажіть, як після цього змінилися середнє й мінімум.

Очікуваний результат: два числа «до» і «після» для кожного зі стовпців.

```
In [12]:
print(C[['speed','density']].agg(['mean', 'min']))
neg_speed = (C['speed'] < 0).sum()
neg_density = (C['density'] < 0).sum()
print(neg_speed,neg_density)

Cnew = C.loc[C['speed'] < 0, 'speed'] = np.nan
Cnew = C.loc[C['density'] < 0, 'density'] = np.nan
```

```
print(C[['speed','density']].agg(['mean', 'min']))
      speed density
mean 506.547421 2.907654
min  -1.000000 -1.000000
8 8
```

```
      speed density
mean 513.394604 2.960371
min 277.000000 0.100000
```

Відповідь 3.2: це значення коли швидкість і густину не зафіксували, їх 8, середнє і мінімум спотворювали відємними значеннями їх не треба враховувати

Завдання 3.3 — питання на подумати

У таблиці A є стовпці, для яких describe() слухняно рахує середнє й стандартне відхилення, хоча ці числа не мають жодного сенсу.

Знайдіть їх і поясніть своїми словами, чому середнє для них безглузде.

Підказка: не кожне число в таблиці є резуль т а т ом вимірювання.

Це питання не має однієї «правильної» відповіді з підручника — на нього ви відповідаєте з власного здорового глузду. Формальне пояснення буде на лекції 3.

```
In [ ]:
```

Відповідь 3.3: я думаю що безглуздими є середнє значення років днів ітд.

Етап 4. Об'єднання трьох таблиць в одну

Таблиці мають різний крок у часі: 5 хвилин, година і доба. Щоб працювати з ними разом, потрібна спільна сітка. Беремо **годину**.

Кожна таблиця потребує своєї дії:

- 1. **A: 5 хвилин → година.** Кілька рядків згортаються в один — це resample + агрегація.
- 2. **C: уже година.** Просте з'єднання по спільному стовпцю ts — merge .
- 3. **B: доба → година.** Навпаки, одне значення розтягується на 24 години доби.

Завдання 4.1

Зведіть таблицю A до погодинної сітки. Для кожного потоку порахуйте**два** числа за годину: середнє і максимум.

```
In [13]:
# ВАШ КОД

At = A.resample("h",on='ts').mean().copy()
a = At.agg(['mean','max'])
Bt = B.set_index('ts').resample('1h').ffill()
print(a)

      YYYY  MM  DD  hhmm  Modified_Julian_Day  Seconds_of_the_day  P>1  P>5  P>10  P>30  P>50  P>100  E>0.8  E>2.
0
mean 2017.0  8.84 13.96 1177.5          58005.0          43050.0  689.154356 156.589812 76.454218 18.831273 7.443857 1.658624 81842.468184 11
397.048492
max 2017.0  9.00 31.00 2327.5          58017.0          84450.0 15908.333333 2306.666667 1243.333333 387.083333 180.833333 52.933333 253916.666667
106916.666667
```

Завдання 4.2

У вашому завданні названо агрегат (середнє , максимум , медіана або мінімум).

Візьміть ваш потік за одну добу, порахуйте для нього по годинах ваш агрегат і ще один на ваш вибір, і побудуйте обидві криві на одному графіку.

Питання: чим вони відрізняються і в якій ситуації різниця між ними стане суттєвою?

```
In [14]:
A_dob = A.set_index('ts').loc['2017-08-28': '2017-08-28']


p50_hourly = A_dob['P>50'].resample('1h').agg(['max', 'median'])
print(p50_hourly)
plt.figure(figsize=(10, 4))
plt.plot(p50_hourly.index, p50_hourly['max'], label='max')
plt.plot(p50_hourly.index, p50_hourly['median'], label='median')

plt.title('Погодинна динаміка P>50 за добу (max vs median)')
plt.xlabel('Час ')
plt.ylabel('Потік частинок')

plt.legend()

plt.show()
```

ts	max	median
2017-08-28 00:00:00	0.1780	0.06130
2017-08-28 01:00:00	0.0798	0.05315
2017-08-28 02:00:00	0.1110	0.06275
2017-08-28 03:00:00	0.1390	0.05795
2017-08-28 04:00:00	0.1420	0.06155
2017-08-28 05:00:00	0.0932	0.05565
2017-08-28 06:00:00	0.1060	0.06700
2017-08-28 07:00:00	0.1550	0.06350
2017-08-28 08:00:00	0.1380	0.07270
2017-08-28 09:00:00	0.1090	0.07570
2017-08-28 10:00:00	0.1060	0.06100
2017-08-28 11:00:00	0.1020	0.05575
2017-08-28 12:00:00	0.0962	0.06965
2017-08-28 13:00:00	0.0892	0.05430
2017-08-28 14:00:00	0.1840	0.07980
2017-08-28 15:00:00	0.1430	0.05785
2017-08-28 16:00:00	0.1250	0.07425
2017-08-28 17:00:00	0.1450	0.07600
2017-08-28 18:00:00	0.1610	0.05700
2017-08-28 19:00:00	0.1210	0.06500
2017-08-28 20:00:00	0.0683	0.05155
2017-08-28 21:00:00	0.1330	0.07890
2017-08-28 22:00:00	0.1260	0.06375
2017-08-28 23:00:00	0.1210	0.08165



Відповідь 4.2: криві повторюють зростання та спадання, але відрізняються амплітудою. Різниця між ними стане суттєвою при різкому сплеску максимального значення.

Завдання 4.3

Об'єднайте три таблиці в одну — назвіть її `M`. Виведіть її розмір і всі рядки, у яких є хоча б один пропуск.

Зверніть увагу: таблиці закінчуються не в один і той самий момент. Тому результат залежить від того, який тип об'єднання ви оберете (`how='inner'` чи `how='outer'`). Спробуйте обидва, подивіться, чим відрізняється кількість рядків, і поясніть свій вибір.

```
In [15]:
# ВАШ КОД
type = 'outer'
```

```
M = pd.merge(At,Bt.reset_index()[['ts','F10.7']],on='ts',how=type).merge(C[['ts','speed','density']],on='ts',how=type)
M
```

Out[15]:

	ts	YYYY	MM	DD	hhmm	Modified_Julian_Day	Seconds_of_the_day	P>1	P>5	P>10	
0	2017-08-28 00:00:00	2017.0	8.0	28.0	27.5	57993.0	1650.0	9.778333	0.324917	0.192917	0.000000
1	2017-08-28 01:00:00	2017.0	8.0	28.0	127.5	57993.0	5250.0	7.994167	0.291667	0.156583	0.000000
2	2017-08-28 02:00:00	2017.0	8.0	28.0	227.5	57993.0	8850.0	6.099167	0.283000	0.177667	0.000000
3	2017-08-28 03:00:00	2017.0	8.0	28.0	327.5	57993.0	12450.0	4.752500	0.236833	0.166333	0.000000
4	2017-08-28 04:00:00	2017.0	8.0	28.0	427.5	57993.0	16050.0	4.158333	0.334917	0.208333	0.000000
...	...	...	...	...	...	...	...	...	...	...	...
596	2017-09-21 20:00:00	2017.0	9.0	21.0	2027.5	58017.0	73650.0	42.102500	0.397500	0.226833	0.000000
597	2017-09-21 21:00:00	2017.0	9.0	21.0	2127.5	58017.0	77250.0	50.783333	0.489250	0.317583	0.000000
598	2017-09-21 22:00:00	2017.0	9.0	21.0	2227.5	58017.0	80850.0	39.000000	0.350000	0.200250	0.000000
599	2017-09-21 23:00:00	2017.0	9.0	21.0	2327.5	58017.0	84450.0	28.825000	0.465000	0.257833	0.000000
600	2017-09-22 00:00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

601 rows × 18 columns

Відповідь 4.3: погодинне A 600 погодинне B 577 рядок погодинне C 601 рядок тип inner дає 577 рядків тому що B має найменше рядків, іннер зєднує тільки ті рядки де є всі дані без пропусків тип outer дає 601 рядків тому що включає всі рядки і якщо нема даних для певного часу то ставить NaN

Вибрано outer щоб не втрачати всі дані якщо в якісь таблиці їх нема.

Завдання 4.4 — поділ на групи

Щоб далі було що з чим порівнювати, поділіть години на три групи за значенняммаксимуму потоку P>10 за годину:

Група	Умова
тиха	менше 10
активна	від 10 до 1000
дуже активна	1000 і більше

Додайте до М стовпець група і виведіть, скільки годин потрапило в кожну.

Це не вигадані числа: саме такі пороги використовує метеослужба космічної погоди NOAA. Чому вони саме такі — питання не сьогоднішньої роботи.

```
In [16]:
# ВАШ КОД
def group(val):
    if val < 10:
        return 'тиха'
    elif val < 1000:
        return 'активна'
    else:
        return 'дуже активна'
M['група'] = [group(i) for i in M['P>10']]

M
```

Out[16]:

	ts	YYYY	MM	DD	hhmm	Modified_Julian_Day	Seconds_of_the_day	P>1	P>5	P>10	
0	2017-08-28 00:00:00	2017.0	8.0	28.0	27.5	57993.0	1650.0	9.778333	0.324917	0.192917	0.
1	2017-08-28 01:00:00	2017.0	8.0	28.0	127.5	57993.0	5250.0	7.994167	0.291667	0.156583	0.
2	2017-08-28 02:00:00	2017.0	8.0	28.0	227.5	57993.0	8850.0	6.099167	0.283000	0.177667	0.
3	2017-08-28 03:00:00	2017.0	8.0	28.0	327.5	57993.0	12450.0	4.752500	0.236833	0.166333	0.
4	2017-08-28 04:00:00	2017.0	8.0	28.0	427.5	57993.0	16050.0	4.158333	0.334917	0.208333	0.
...	...	...	...	...	...	...	...	...	...	...	...
596	2017-09-21 20:00:00	2017.0	9.0	21.0	2027.5	58017.0	73650.0	42.102500	0.397500	0.226833	0.
597	2017-09-21 21:00:00	2017.0	9.0	21.0	2127.5	58017.0	77250.0	50.783333	0.489250	0.317583	0.
598	2017-09-21 22:00:00	2017.0	9.0	21.0	2227.5	58017.0	80850.0	39.000000	0.350000	0.200250	0.
599	2017-09-21 23:00:00	2017.0	9.0	21.0	2327.5	58017.0	84450.0	28.825000	0.465000	0.257833	0.
600	2017-09-22 00:00:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

601 rows × 19 columns

Самоперевірка етапу 4.

In [17]:
assert M **is not** None, 'таблиця M не побудована'
assert 'ts' **in** M.columns, 'у таблиці M потрібен стовпець ts'
assert 'група' **in** M.columns, 'у таблиці M потрібен стовпець «група»'
assert 590 <= len(M) <= 605, 'очікується близько 600 рядків, а є %d — перевірте об'єднання' % len(M)
print('Етап 4 пройдено:', len(M), 'рядків')
Етап 4 пройдено: 601 рядків

Етап 5. П'ять графіків — п'ять питань

Графік будується як **відповідь на питання**, а не «щоб був».

Вимоги до кожного графіка:

- підписані обидві осі, з одиницями вимірювання;
- заголовок;
- під графіком, у текстовій клітинці, — **одне речення про дані** Не «на графіку зображено потік протонів», а твердження на кшталт «більшість годин потік не перевищує 60, але кілька годин дають значення у сотні разів більші».

Не кожне питання має відповідь «так, зв'язок є». Якщо на графіку нічого не видно — так і напишіть. Відсутність зв'язку — це теж результат, і чесно про неї написати важливіше, ніж підбирати ракурс, у якому «щось наче проглядається».

Графік 1. Як розподілені значення вашого потоку?

Побудуйте гістограму вашого потоку (середнє за годину). Порахуйте окремо середнє й медіану цього стовпця.

Якщо гістограма вийде нечитабельною — стовпчик біля нуля і порожньо далі — не залишайте так. Спробуйте побудувати гістограму від логарифма значень (`np.log10`) і подивіться, що зміниться.

Питання: чому середнє й медіана так сильно відрізняються?

```
In [18]:
import numpy as np
import matplotlib.pyplot as plt


df = M
p50_clean = df["P>50"].dropna()

plt.figure(figsize=(10, 5))
plt.hist(np.log10(p50_clean), bins=40, edgecolor='black', alpha=0.7)

ticks = [-1, 0, 1, 2, 3]
labels = ['0.1', '1', '10', '100', '1000']
plt.xticks(ticks, labels)

plt.title("Значення P>50 протягом всього періоду замірів")
plt.xlabel("Потік протонів P>50, Protons/cm²-s-sr")
plt.ylabel("Кількість замірів")

plt.show()
```



Висновок: більшість часу потік протонів знаходиться в спокійному стані, але деколи він збільшується і може зростати до 100 чи навіть 1000 разів.

Графік 2. Чи відрізняється швидкість вітру між групами годин?

Побудуйте діаграму розмаху (`boxplot`) швидкості сонячного вітру окремо для кожної групи з завдання 4.4.

```
In [19]:
```

ВАШ КОД

```
df = M
groups = df['група'].unique()
df = [df[df['група'] == g]['speed'].dropna() for g in groups]
print(df)

plt.figure()
plt.boxplot(df, tick_labels=groups)

plt.title('Розподіл швидкості сонячного вітру за групами активності')
plt.xlabel('Група активності')
plt.ylabel('Швидкість (speed), км/с')


plt.show()
```

```

285.0
1 305.0
2 309.0
3 304.0
4 302.0
...
595 394.0
596 379.0
597 380.0
598 387.0
599 380.0
Name: speed, Length: 408, dtype: float64, 193 583.0
194 576.0
195 577.0
196 570.0
197 558.0
...
420 448.0
421 448.0
422 457.0
423 469.0
424 484.0
Name: speed, Length: 167, dtype: float64, 334 552.0
336 566.0
337 575.0
338 564.0
339 557.0
340 556.0
341 556.0
342 558.0
343 556.0
344 554.0
345 555.0
346 556.0
347 556.0
348 555.0
349 555.0
350 556.0
351 557.0
600 381.0
Name: speed, dtype: float64]

```

Розподіл швидкості сонячного вітру за групами активності



Висновок: boxplot показує крайніми межами нормальні дані поза центральними 50%, прямокутник центральні 50%, оранджова лінія медіану, а точки це аномальні значення. Гоафік показує що тиха група має високу варіативність швидкостей, вона рівномірна. В активній групі переважають вищі швидкості, є навіть аномально високі. Найактивніша група має невеликий розмах у швидкостях, але зустрічаються аномально високі або низькі швидкості протонів.

Графік 3. Чи пов'язані змінні вашої пари?

Побудуйте діаграму розсіювання для пари з вашого завдання. Порахуйте коефіцієнт кореляції між ними.

In [20]:


```
# ВАШ КОД  
df = M
```

```
df = M[['speed', 'P>10']]
```

```
plt.figure(figsize=(8, 5))
```

```
plt.scatter(df['P>10'], df['speed'])  
plt.title("залежність швидкості від кількості протонів")  
plt.xlabel("кількість протонів")  
plt.ylabel("швидкість протонів")
```

```
coef = df['P>10'].corr(df['speed'])  
print("коефіцієнт кореляції: ",coef)  
коефіцієнт кореляції: 0.07096067649918358
```




****Висновок:****графік показує що більшість вимірів має низькі значення кількості протонів, і їхня швидкість дуже різниться. В той час високі значення кількості протонів тримаються в межах 400-600 км/с. Зв'язку між цими величинами майже нема.

Графік 4. Скільки годин у кожній групі?

Побудуйте стовпчикову діаграму кількості годин за групами. Підпишіть кожен стовпчик кількістю годин і відсотком від загальної кількості.

```
In [21]:  
df = M  
  
df = df.groupby('група').count().reset_index()  
  
count = df['ts'].sum()  
df['ts'] = df['P>50']/count*100  
print(df)  
bars = plt.bar(df['група'],df['ts'])  
labels = [f"{{round(coun)}} \n{pers:.1f}%" for pers, coun in zip(df['ts'],df['ts']*count/100)]  
plt.bar_label(bars,labels=labels)  
plt.ylim(0,100)  
plt.title("Розподіл швидкості сонячного вітру за групами активності")  
plt.xlabel("Група активності")  
plt.ylabel("кількість годин,%")  
  
plt.show()
```

група	ts	YYYY	MM	DD	hhmm	Modified_Julian_Day	Seconds_of_the_day	P>1	P>5	P>10	P>30	P>50	P>100	E>0.8	E>2.0	F10.7	speed	density
0	активна	27.787022	167	167	167	167	167	167	167	167	167	167	167	167	167	167	167	167
1	дуже активна	2.828619	17	17	17	17	17	17	17	17	17	17	17	17	17	18	18	167
2	тиха	69.217970	416	416	416	416	416	416	416	416	416	416	416	393	408	408		



Висновок: найбільше потоків вважаються тихими, а найменше - дуже активними.

Графік 5. Як усе це виглядало в часі?

Побудуйте лінійний графік максимуму потоку P>10 за годину за весь період спостережень.

Якщо крива виявиться нечитабельною — згадайте, що допомогло в графіку 1.

```
In [22]:
# ВАШ КОД
df = M[['P>10','ts']].dropna()
print(df)
plt.figure(figsize=(20,4))
plt.plot(df['ts'],np.log10(df['P>10']))
ticks = [-1, 0, 1, 2, 3]
labels = ['0.1', '1', '10', '100', '1000']
plt.yticks(ticks,labels)

plt.title('Розподіл потоку P>10 протягом всього періоду спостережень')
plt.xlabel('час')
plt.ylabel('кількість протонів')
```

```

P>10      ts
0  0.192917 2017-08-28 00:00:00
1  0.156583 2017-08-28 01:00:00
2  0.177667 2017-08-28 02:00:00
3  0.166333 2017-08-28 03:00:00
4  0.208333 2017-08-28 04:00:00
..      ...
595 0.229833 2017-09-21 19:00:00
596 0.226833 2017-09-21 20:00:00
597 0.317583 2017-09-21 21:00:00
598 0.200250 2017-09-21 22:00:00
599 0.257833 2017-09-21 23:00:00

```

```

[600 rows x 2 columns]
Out[22]:
Text(0, 0.5, 'кількість протонів')

```



Висновок: протягом першого тижня спостережень значення коливаються в межах 0.3 протони/см²-s-sr, потім різко піднімаючись два рази протягом 2 тижнів до 10000 разів, поступово спадаючи до 0.5 протонів/см²-s-sr

Етап 6. Два графіки одних і тих самих даних

Нижче побудовано два графіки. Дані в них **одні й ті самі** — це той самий стовпець з тієї самої таблиці, жодне число не змінено.

Виконайте клітинку й подивіться на обидва.

```

In [23]:
СТОВПЕЦЬ = 'P>10' # <- впишіть назву свого стовпця з МАКСИМУМОМ P>10 за годину

```

```

вікно = M[(M['ts'] >= '2017-08-28') & (M['ts'] < '2017-09-05')]

```

```

fig, ax = plt.subplots(1, 2, figsize=(12, 3.2))

```

```

ax[0].plot(вікно['ts'], вікно[СТОВПЕЦЬ], color='#2a78d6')
ax[0].set_title('Графік 1')
ax[0].tick_params(axis='x', rotation=30)

```

```


ax[1].plot(M['ts'], M[СТОВПЕЦЬ], color='#2a78d6')
ax[1].set_yscale('log')
ax[1].set_title('Графік 2')
ax[1].tick_params(axis='x', rotation=30)

```

```

fig.tight_layout()
plt.show()

```



Завдання 6.1

Дайте відповідь на три питання:

- 1. Який висновок про космічну погоду у вересні 2017 року зробить людина, яка бачила **тільки перший** графік?
- 2. Який висновок зробить людина, яка бачила **тільки другий**?
- 3. Чим ці два графіки відрізняються між собою? Назвіть **дві** відмінності — вони обидві є в коді вище.

Жодне число в обох графіках не підроблене. Різниця виникла тільки через те, як їх побудували.

Відповідь 6.1:


- 1. Висновок з першого графіка: досить стабільна протягом тижня, в кінці відбувся дуже значне погіршення
- 2. Висновок з другого графіка: протягом місяця погода була нестабільна з різкими погіршеннями і покращеннями
- 3. Дві відмінності між ними: дані взяті за різний проміжок часу, в одному погода стабільна але не враховуються інші заміри

Завдання 6.2

Уявіть, що вам потрібно **одним графіком** чесно показати, що відбувалося в цьому періоді. Побудуйте його самі й підпишіть заголовком, який формулює висновок.

Поясніть у клітинці нижче, чому ви обрали саме такий вигляд.

```
In [24]:
# ВАШ КОД
plt.figure(figsize=(20,4))
plt.plot(M['ts'], M[СТОВПЕЦЬ], color='#2a78d6')
plt.yscale('log')
plt.title('Кількість протонів P>10 протягом вересня')
plt.xlabel("час")
plt.ylabel("кількість протонів")
plt.tick_params(axis='x', rotation=30)
```



Відповідь 6.2: Графік 2 цілком описує стан погоди, але я додав підписи щоб було зрозуміліше що описує графік.

Етап 7. Три спостереження та ваше питання

Завдання 7.1

Запишіть **три спостереження** про ці дані, які ви зробили під час роботи.

Спостереження — це твердження, яке спирається на конкретне число або графік з вашого ноутбука. Не «дані цікаві», а, наприклад, «максимальне значення потоку у 2000 разів більше за медіанне, і всі такі години припадають на одні й ті самі три доби».

Для кожного вкажіть, **де саме** у вашій роботі його видно.

Спостереження 1: з графіка 5.2 видно що чим активніша група протонів, тим стабільнішою є їхня швидкість, при чому медіани значень відрізняються до 100 км/с.

Спостереження 2: графік 5.3 показує що більшість вимірів має низькі значення кількості протонів, і їхня швидкість дуже різниться.В той час високі значення кількості протонів тримаються в межах 400-600 км/с. Зв'язку між цими величинами майже нема.

Спостереження 3: за графіком 6.2 видно що погода може бути стабільною,але якщо вона погіршується це відбувається дуже різко і триває до тижня часу.

Завдання 7.2 — ваше індивідуальне питання

Дайте відповідь на додаткове питання зі свого завдання. Відповідь має спиратися на обчислення: наведіть код і результат, а потім сформулюйте висновок словами.

```
In [25]:
# Скільки годин поспіль тривала найдовша неперервна серія «активних» годин (група з етапу 4)?
df = M['група']
max_c = 0
count = 0
for group in df:
    if group == "активна":
        count += 1

    else:
        max_c = np.maximum(count,max_c)
        count = 0
max_c
```

Out[25]:
np.int64(84)
Відповідь 7.2: найдовший цикл активної групи тривав 84 години.

Етап 8. Декларація про використання інструментів штучного інтелекту

Користуватися мовними моделями під час виконання цієї роботи**дозволено**. Це нормальна інженерна практика, і курс про штучний інтелект не має підстав її забороняти.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. **Задекларована допомога порушенням не є.**

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок вашого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці. Якщо код згенеровано, але ви його розумієте — робота зарахована. Якщо не розумієте — не зарахована, незалежно від того, хто його написав.

Завдання 8.1

Заповніть словник. Для кожного етапу оберіть одне з формулювань:

- 'ні' — інструментами ШІ не користувався;
- 'синтаксис' — питав про назву функції або синтаксис, код писав сам;
- 'код, перевірено' — код згенеровано, я його прочитав, перевірів і розумію;
- 'текст, перероблено' — згенеровано чернетку тексту, яку я переписав по суті;
- 'текст, як є' — згенерований текст залишено майже без змін.

Останній варіант не заборонений, але прямо впливає на оцінку: бали ставляться за висновки, а не за наявність абзацу.

```
In [26]:
ІНСТРУМЕНТИ_ШІ = 'Gemini' # напр. 'ChatGPT' або 'не використ овував'
```

```
ДЕКЛАРАЦІЯ = {
    'етапи 1–2, читання файлу та розбір таблиць': 'ні',
    'етап 3, паспорт даних і дивні значення': 'синтаксис',
    'етап 4, об'єднання таблиць': 'ні',
    'етап 5, побудова графіків': 'код, перевірено',
    'етап 5, формулювання висновків': 'ні',
    'етапи 6–7, порівняння графіків і спостереження': 'ні',
}
```

```
# Що саме ви перевірили за згенерованим кодом чи текстом — конкретно:
# які числа звірили, що переписали, де знайшли помилку.
ЩО_ПЕРЕВІРЕНО = 'допоміг з логарифмуванням, не знав як правильно зробити, перевірів чи певний діапазон має дійсно такі зна

# True означає: я можу пояснити кожний рядок свого коду, відтворити будь-який
# результат цієї роботи та внести зміни в код на вимогу під час захисту.
ПІДТВЕРДЖУЮ = True
In [27]:
```

```
# --- перевірка повноти декларації: клітинку не редагувати -----
ДОЗВОЛЕНІ = {'ні', 'синтаксис', 'код', 'перевірено', 'текст', 'перероблено', 'текст, як є'}
```

```
assert INSTRUMENTИ_ШІ.strip(), 'Вкажіть інструменти або напишіть «не використовував»'
порожні = [k for k, v in ДЕКЛАРАЦІЯ.items() if not str(v).strip()]
assert not порожні, 'Не заповнено пункти декларації: %s' % ' '.join(порожні)
чужі = {v for v in ДЕКЛАРАЦІЯ.values() if v not in ДОЗВОЛЕНІ}
assert not чужі, 'Недопустимі значення: %s. Оберіть з переліку вище.' % ' '.join(sorted(чужі))
assert len(ЩО_ПЕРЕВІРЕНО.strip()) >= 120, ('Опишіть конкретніше, що саме ви перевірили '
                                             '(зараз %d символів, потрібно щонайменше 120)'
                                             % len(ЩО_ПЕРЕВІРЕНО.strip()))
assert ПІДТВЕРДЖУЮ is True, 'Підтвердьте, що можете пояснити власний код на захисті'
```

```
print('ДЕКЛАРАЦІЯ ПРО ВИКОРИСТАННЯ ІНСТРУМЕНТІВ ШІ')
print('=' * 78)
print('%-46s %s' % ('автор:', ПІБ))
print('%-46s %s' % ('інструменти:', INSTRUMENTИ_ШІ))
print('=' * 78)
for k, v in ДЕКЛАРАЦІЯ.items():
    print('%-46s %s' % (k + ': ', v))
print('=' * 78)
print('перевірено автором:')
print(ЩО_ПЕРЕВІРЕНО)
print('=' * 78)
print('Автор підтверджує, що може пояснити кожен рядок коду під час захисту.')
```

ДЕКЛАРАЦІЯ ПРО ВИКОРИСТАННЯ ІНСТРУМЕНТІВ ШІ

```
=====
автор: Басараб Дмитрій
інструменти: Gemini
=====
```

```
етапи 1–2, читання файлу та розбір таблиць: ні
етап 3, паспорт даних і дивні значення: синтаксис
етап 4, об'єднання таблиць: ні
етап 5, побудова графіків: код, перевірено
етап 5, формулювання висновків: ні
етапи 6–7, порівняння графіків і спостереження: ні
=====
```

```
перевірено автором:
допоміг з логарифмуванням, не знав як правильно зробити, перевірів чи певний діапазон має дійсно такі значення, в основному по синтаксису і по переформулюванню питань питав бо не було зрозуміло що вимагають
=====
Автор підтверджує, що може пояснити кожен рядок коду під час захисту.
```

Крок 9. Збереження результату та фінальна самоперевірка

Об'єднана таблиця знадобиться вам у лабораторних роботах № 3 і № 4 — збережіть її й не втрачайте до кінця семестру.

```
In [28]:
M.to_csv('master_hourly.csv', index=False)
print('збережено:', M.shape)

збережено: (601, 19)
In [29]:
# --- фінальна самоперевірка -----
перевірки = {
    'ПІБ і варіант заповнено': bool(ПІБ) and bool(ВАРІАНТ),
    'таблиця A (7200 рядків)': len(A) == 7200,
    'таблиця B (25 рядків)': len(B) == 25,
    'таблиця C (601 рядок)': len(C) == 601,
    'таблиці об'єднано': M is not None and 590 <= len(M) <= 605,
    'стовпець «група» є': 'група' in M.columns,
    'усі дати у 2017 році': int(pd.to_datetime(M['ts']).dt.year.min()) == 2017,
    'декларацію заповнено': bool(ІНСТРУМЕНТИ_ШІ.strip()) and ПІДТВЕРДЖУЮ is True,
}
for k, v in перевірки.items():
    print(('ОК ' if v else 'НЕ ОК') + ' ' + k)

if all(перевірки.values()):
    print('\nТехнічна частина роботи виконана.')
    print('Тепер переконайтеся, що заповнені ВСІ клітинки з відповідями та висновками,')
    print('і виконайте Kernel → Restart & Run All перед здачею.')
```

OK ПІБ і варіант заповнено
OK таблиця А (7200 рядків)
OK таблиця В (25 рядків)
OK таблиця С (601 рядок)
OK таблиці об'єднано
OK стовпець «група» є
OK усі дати у 2017 році
OK декларацію заповнено

Технічна частина роботи виконана.

Тепер переконайтеся, що заповнені ВСІ клітинки з відповідями та висновками,
і виконайте Kernel → Restart & Run All перед здачею.